AgroAlerta

Relatório de assertividade da IA (Claude)

Como a IA foi testada e quanto acertou nos módulos de monitoramento climático e de mercado

Emitido em 27/10/2026, 23:17:26 · AgroAlerta · TCC

1. Resumo do resultado

ÍNDICE DE ASSERTIVIDADE	ACERTO OBJETIVO	RESPOSTAS SATISFATÓRIAS	RESPOSTAS DA API
96,7%	**100%**	**100%**	**120**
média das notas ÷ 5	120 de 120 respostas	60 de 60 cenários	0 simuladas · 0 excluídas

Em 60 cenários (30 de clima e 30 de mercado), com 120 respostas reais da API da Anthropic, o Claude acertou 100% das classificações objetivas (nível geral e riscos no clima; alta, queda ou estável no mercado) e obteve nota média de cerca de 4,8 em 5 nos critérios de qualidade, o que corresponde ao índice de assertividade de 96,7%.

Módulo	Cenários	Índice de assertividade	Acerto objetivo (IC 95%)	Satisfatórias
Monitoramento climático	30	98,6% (média 4,9)	100% (94,0% a 100%)	30/30
Mercado	30	94,8% (média 4,7)	100% (94,0% a 100%)	30/30

2. Objetivo da avaliação

O orientador pediu a avaliação da assertividade da IA. O objetivo é medir, com resultados mensuráveis, se o Claude interpreta corretamente (a) os dados do monitoramento climático (temperatura, chuva, vento e os alertas do motor de regras) e (b) as séries de preços do mercado (altas, quedas e estabilidade), produzindo respostas coerentes, claras, relevantes, sem informações inventadas e consistentes entre repetições.

3. Como a IA foi testada

Etapa	O que foi feito
Cenários	30 de clima (15 café e 15 soja) e 30 de mercado (15 café e 15 soja), controlados e reproduzíveis. Clima: normal (7), risco_unico (9), limite (9), combinado (5). Mercado: alta (6), queda (6), estavel (6), lateral_volatil (2), reversao (4), alta_com_realizacao (2), queda_com_repique (2), reversao_estavel (2).
Gabarito (clima)	Calculado pelo motor de regras real do sistema (limiares de geada, estiagem, excesso de chuva, vento e chuva na colheita). Inclui casos-limite (por exemplo 2,0 e 5,5 °C; 149 mm; 59 e 60 km/h) para testar falsos alarmes e omissões.
Gabarito (mercado)	Regra única de tendência sobre a variação líquida do período: alta se maior ou igual a +2%, queda se menor ou igual a -2%, estável entre os dois. Séries de 14 observações geradas com semente fixa; variações a pelo menos 1 ponto percentual do limiar.
Execução	Cada cenário foi enviado ao Claude duas vezes, com o mesmo prompt (clima-v1 e mercado-v2). Modelo avaliado: claude-haiku-4-5-20251001. A resposta é um JSON, validado e convertido no texto que o produtor lê.
Avaliação	Um modelo diferente e mais forte, claude-sonnet-4-6 (temperatura 0), pontuou de 1 a 5 quatro critérios, recebendo os dados enviados, o gabarito e os pontos-chave esperados. A consistência não passa pelo juiz: é calculada entre as duas execuções.
Checagens automáticas	Comparação com o gabarito (nível geral, conjunto de riscos, tendência), validade do JSON e verificação de números citados que não existem nos dados enviados.
Proveniência	Cada resposta tem requestId (req_...) e respostaId (msg_...) devolvidos pela API da Anthropic, gravados em registro-chamadas.jsonl. A avaliação não possui fallback simulado: respostas sem esses identificadores seriam excluídas e contadas.

Critérios de avaliação (escala inteira de 1 a 5)

Critério	Pergunta	5 = ... | 3 = ... | 1 = ...
Coerência	A resposta é correta e coerente com os dados e com o gabarito (níveis, tendência, riscos), sem se contradizer?	5: totalmente coerente com dados e gabarito, sem contradições | 3: pequena imprecisão ou ressalva que não muda a conclusão | 1: contradiz os dados ou o gabarito
Clareza	O texto é simples, objetivo e fácil de entender por um produtor rural?	5: direto, bem organizado, linguagem simples | 3: compreensível, mas com rodeios ou termos desnecessários | 1: confuso ou ilegível
Relevância	A resposta cobre o que importa para a decisão do produtor (pontos-chave) e evita ruído ou alarmes desnecessários?	5: cobre todos os pontos-chave e nada fora de lugar | 3: cobre parte do essencial ou traz conteúdo supérfluo | 1: omite o essencial ou foge do assunto
Ausência de informações inventadas	A resposta usa só o que está nos dados? Contexto geral só é aceitável se estiver claramente rotulado como geral.	5: nada fora dos dados fornecidos | 3: uma afirmação específica sem sustentação nos dados | 1: várias invenções (números, eventos, causas)
Consistência	As duas execuções do mesmo cenário chegam à mesma conclusão?	Calculada: nota = 1 + 4 x concordância (clima: nível geral e conjunto de riscos; mercado: mesma tendência)

4. Como a porcentagem é calculada

Indicador	Fórmula	Resultado
Índice de assertividade	média das 5 notas de cada cenário, dividida por 5 (por módulo; geral ponderado pelo número de cenários)	Clima 98,6% | Mercado 94,8% | Geral 96,7%
Acerto objetivo	respostas corretas dividido pelas respostas. Clima: nível geral e conjunto de riscos idênticos ao gabarito. Mercado: tendência igual ao gabarito	100% (120/120), IC 95%: 96,9% a 100%
Respostas satisfatórias	cenários com média das 5 notas maior ou igual a 4,0 e nenhum critério abaixo de 3	100% (60/60), IC 95%: 94,0% a 100%

Os intervalos de confiança são de Wilson (95%) e mostram a incerteza de uma amostra pequena: com 30 cenários por módulo, 100% observado é compatível com um valor verdadeiro a partir de cerca de 94%.

5. Resultados por módulo

Monitoramento climático (30 cenários, 60 respostas)

Critério	Média (1 a 5)	Desvio-padrão	% nota 4 ou mais
Coerência	5,0	0,0	100,0%
Clareza	5,0	0,0	100,0%
Relevância	4,9	0,2	100,0%
Ausência de informações inventadas	4,8	0,4	100,0%
Consistência	5,0	0,0	100,0%

Métrica objetiva (contra o motor de regras)	Valor
Respostas em JSON válido	100,0%
Nível geral correto	100,0%
Conjunto de riscos idêntico ao do motor	100,0%
Precisão dos riscos citados	100,0%
Cobertura dos riscos do motor (recall)	100,0%
Respostas com falso alarme	0,0%
Respostas citando número fora dos dados	0,0%

Categoria de cenário	Cenários	Média geral	Satisfatórios
normal	7	5,0	7 de 7
risco_unico	9	4,9	9 de 9
limite	9	5,0	9 de 9
combinado	5	4,9	5 de 5

Mercado (30 cenários, 60 respostas)

Critério	Média (1 a 5)	Desvio-padrão	% nota 4 ou mais
Coerência	4,9	0,2	100,0%
Clareza	4,7	0,4	100,0%
Relevância	4,6	0,4	100,0%
Ausência de informações inventadas	4,5	0,4	93,3%
Consistência	5,0	0,0	100,0%

Métrica objetiva (contra a regra de ±2%)	Valor
Respostas em JSON válido	100,0%
Tendência correta (alta, queda ou estável)	100,0%
Respostas citando número fora dos dados	6,7%

Gabarito \ Claude	alta	estável	queda	sem formato
alta	20	0	0	0
estável	0	20	0	0
queda	0	0	20	0

Categoria de cenário	Cenários	Média geral	Satisfatórios
alta	6	4,7	6 de 6
queda	6	4,8	6 de 6
estavel	6	4,6	6 de 6
lateral_volatil	2	4,6	2 de 2
reversao	4	4,9	4 de 4
alta_com_realizacao	2	4,9	2 de 2
queda_com_repique	2	4,9	2 de 2
reversao_estavel	2	4,8	2 de 2

6. Exemplos reais de respostas

Monitoramento climático

Maior nota - C05 (limite): Mínima de 5,5 °C, logo acima do limiar de geada

Dados enviados ao modelo:
Talhão: Talhão C05 (café arábica, fase vegetativo)
Leitura meteorológica (fonte cenario-controlado):
- Temperatura mínima prevista nos próximos 7 dias: 5.5 °C
- Chuva acumulada prevista nos próximos 7 dias: 25 mm
- Dias secos consecutivos até ontem: 2
- Probabilidade máxima de chuva nos próximos 7 dias: 40%
- Vento máximo previsto: 15 km/h
- Evapotranspiração (ET0) prevista em 7 dias: 28 mm
Alertas calculados pelo motor de regras (avaliação determinística da cultura e fase):
- nenhum alerta disparado

Resposta do Claude (requestId req_011CgTo5TbZpntwT8wnnKsth):
Nível geral: baixo
Resumo: Não há risco relevante no momento para o Talhão C05. As condições meteorológicas previstas nos próximos 7 dias estão dentro dos parâmetros normais para a fase vegetativa do café arábica.
Riscos: nenhum
Recomendações: nenhuma

Gabarito: Nenhum risco esperado; nível geral baixo.
Notas: coerência 5,0, clareza 5,0, relevância 5,0, ausência de invenção 5,0, consistência 5,0 (média 5,0).
Observação do avaliador: Nenhuma informação além dos dados fornecidos. Afirmações genéricas são adequadas e não inventadas.

Menor nota - S08 (risco_unico): Ventos de 65 km/h

Dados enviados ao modelo:
Talhão: Talhão S08 (soja, fase vegetativo)
Leitura meteorológica (fonte cenario-controlado):
- Temperatura mínima prevista nos próximos 7 dias: 14 °C
- Chuva acumulada prevista nos próximos 7 dias: 25 mm
- Dias secos consecutivos até ontem: 2
- Probabilidade máxima de chuva nos próximos 7 dias: 40%
- Vento máximo previsto: 65 km/h
- Evapotranspiração (ET0) prevista em 7 dias: 28 mm
Alertas calculados pelo motor de regras (avaliação determinística da cultura e fase):
- [alto] Ventos fortes: Ventos de até 65 km/h previstos. (janela: próximos dias)

Resposta do Claude (requestId req_011CgToBAX5SwBZCXx4ydAxA):
Nível geral: alto
Resumo: Há risco alto de ventos fortes nos próximos dias, com rajadas de até 65 km/h previstas. A chuva acumulada de 25 mm e a evapotranspiração de 28 mm mantêm o balanço hídrico adequado para a fase vegetativa. Não há risco de geada ou estiagem no período.
Riscos:
- vento (alto): Ventos máximos de 65 km/h previstos para os próximos dias podem danificar a soja em fase vegetativa.
Recomendações:
- Verificar estruturas de suporte e tutoragem na lavoura
- Evitar aplicações de defensivos durante os picos de vento previstos
- Monitorar plantas após as rajadas para identificar danos

Gabarito: Nível geral esperado: alto. Riscos esperados (tipo, nível): vento (alto).
Notas: coerência 5,0, clareza 5,0, relevância 5,0, ausência de invenção 4,0, consistência 5,0 (média 4,8).
Observação do avaliador: Afirmação sobre tutoragem não tem base nos dados fornecidos; demais informações são sustentadas pelos dados.

Mercado

Maior nota - MS13 (alta_com_realizacao): Alta com realização no fim, fechando em +4%

Dados enviados ao modelo:
Cultura: soja
Unidade: saca 60kg
Observações: 14 (de 2026-09-01 a 2026-09-14)
Preço inicial: 128; preço final: 133.12; variação: 4%
Mínimo: 128 em 2026-09-01; máximo: 136.82 em 2026-09-08
Série: 2026-09-01=128; 2026-09-02=129.35; 2026-09-03=130.43; 2026-09-04=131.79; 2026-09-05=133.2; 2026-09-06=134.66; 2026-09-07=136.6; 2026-09-08=136.82; 2026-09-09=135.98; 2026-09-10=135.27; 2026-09-11=134.66; 2026-09-12=134.37; 2026-09-13=133.9; 2026-09-14=133.12

Resposta do Claude (requestId req_011CgToNfKUerdEbE9dk2vfL):
Tendência: alta
Resumo: O preço da soja apresentou alta de 4% no período, subindo de R$ 128,00 para R$ 133,12 a saca de 60kg. A cotação saiu de R$ 128,00 no início (1º de setembro) e atingiu o máximo de R$ 136,82 no dia 8 de setembro, apresentando uma reversão clara a partir dali com queda gradual até o final do período. Apesar da queda dos últimos dias, o preço permanece R$ 5,12 acima do valor inicial. Recomenda-se acompanhar os próximos pregões com atenção, pois o comportamento recente sugere pressão para baixo; considere suas necessidades de comercialização no contexto dessa volatilidade de curto prazo.

Gabarito: Tendência esperada pela regra: alta (variação líquida de 4%; alta >= +2%, queda <= -2%, estável entre os dois). Formato da série: Alta com realização no fim, fechando em +4%.
Notas: coerência 5,0, clareza 5,0, relevância 5,0, ausência de invenção 5,0, consistência 5,0 (média 5,0).
Observação do avaliador: Todos os valores e afirmações derivam diretamente dos dados fornecidos, sem acréscimos externos.

Menor nota - MS07 (estavel): Estável, leve alta de +0,4%

Dados enviados ao modelo:
Cultura: soja
Unidade: saca 60kg
Observações: 14 (de 2026-09-01 a 2026-09-14)
Preço inicial: 128; preço final: 128.51; variação: 0.4%
Mínimo: 127.72 em 2026-09-02; máximo: 128.67 em 2026-09-09
Série: 2026-09-01=128; 2026-09-02=127.72; 2026-09-03=128.08; 2026-09-04=128.01; 2026-09-05=127.83; 2026-09-06=127.99; 2026-09-07=128.18; 2026-09-08=128.59; 2026-09-09=128.67; 2026-09-10=128.67; 2026-09-11=128.19; 2026-09-12=128.21; 2026-09-13=128.4; 2026-09-14=128.51

Resposta do Claude (requestId req_011CgToLWPAcjiLnoQTVJFUd):
Tendência: estavel
Resumo: O preço da soja apresentou comportamento estável no período de 1º a 14 de setembro, com variação de apenas 0,4% entre o preço inicial de R$ 128,00 e final de R$ 128,51 a saca. A cotação oscilou entre o mínimo de R$ 127,72 (02/09) e máximo de R$ 128,67 (09/10), refletindo pequenas variações sem tendência clara de movimento. Houve uma leve recuperação no meio do período, com pico no dia 9 de setembro, seguida de pequena correção e posterior estabilização nos últimos dias. Para o curto prazo, o produtor deve monitorar se a cotação consegue sustentar-se acima de R$ 128,50 ou se voltará aos ...

Gabarito: Tendência esperada pela regra: estavel (variação líquida de 0.4%; alta >= +2%, queda <= -2%, estável entre os dois). Formato da série: Estável, leve alta de +0,4%.
Notas: coerência 4,5, clareza 4,0, relevância 4,0, ausência de invenção 4,0, consistência 5,0 (média 4,3).
Observação do avaliador: Todos os números têm base nos dados; 'mercado ainda busca direção' é interpretação sem sustentação explícita nos dados fornecidos.

7. Proveniência e consumo da API

Papel	Modelo	Chamadas ok	Falhas	Tokens de entrada	Tokens de saída
geracao	claude-haiku-4-5-20251001	120	0	68.886	25.192
juiz	claude-sonnet-4-6	120	0	146.276	22.628

Total de chamadas registradas: 241 (inclui o diagnóstico de autenticação). Execução em 27/10/2026, 22:49:20.

8. Como interpretar e limitações

- O índice de assertividade (96,7%) resume a qualidade das respostas pelos cinco critérios; o acerto objetivo (100%) mede apenas se a conclusão bate com o gabarito. São números diferentes e devem ser citados juntos.
- O resultado está próximo do teto: a medição discrimina pouco entre respostas boas. O módulo climático é uma tarefa fácil porque o modelo recebe os alertas já calculados; o resultado mede fidelidade ao motor de regras, não verdade agronômica.
- A menor média nos dois módulos foi a de 'ausência de informações inventadas' (4,8 no clima e 4,5 no mercado): detalhes sem base nos dados, como 'tutoragem', 'resistência técnica' ou 'mercado ainda busca direção'. Em seguida vêm relevância e clareza.
- O avaliador é outro modelo de linguagem e pode ter vieses. O arquivo validacao-humana.csv traz uma amostra para a equipe pontuar à mão e comparar com o juiz.
- São 30 cenários por módulo e duas execuções por cenário (amostra pequena). Os prompts foram refinados antes da medição; os números valem para as versões e o modelo indicados.
- Cenários agronomicamente ambíguos ficaram de fora para o gabarito ser inequívoco. Para um teste mais exigente: incluí-los e retirar os alertas do contexto da IA climática.