AgroAlerta

Relatório de assertividade da IA (Claude)

Como a IA foi testada e quanto acertou nos módulos de monitoramento climático e de mercado

Emitido em 29/10/2026, 18:04:07 · AgroAlerta · TCC

1. Resumo do resultado

ÍNDICE DE ASSERTIVIDADE
96,9%
média das notas ÷ 5

ACERTO OBJETIVO
100%
120 de 120 respostas

RESPOSTAS SATISFATÓRIAS
100%
60 de 60 cenários

RESPOSTAS DA API
120
0 simuladas · 0 excluídas

Em 60 cenários (30 de clima e 30 de mercado), com 120 respostas reais da API da Anthropic, o Claude acertou 100% das classificações objetivas (nível geral e riscos no clima; alta, queda ou estável no mercado) e obteve nota média de cerca de 4,8 em 5 nos critérios de qualidade, o que corresponde ao índice de assertividade de 96,9%.

Módulo	Cenários	Índice de assertividade	Acerto objetivo (IC 95%)	Satisfatórias
Monitoramento climático	30	98,8% (média 4,9)	100% (94,0% a 100%)	30/30
Mercado	30	95,0% (média 4,8)	100% (94,0% a 100%)	30/30

2. Objetivo da avaliação

O orientador pediu a avaliação da assertividade da IA. O objetivo é medir, com resultados mensuráveis, se o Claude interpreta corretamente (a) os dados do monitoramento climático (temperatura, chuva, vento e os alertas do motor de regras) e (b) as séries de preços do mercado (altas, quedas e estabilidade), produzindo respostas coerentes, claras, relevantes, sem informações inventadas e consistentes entre repetições.

3. Como a IA foi testada

Etapa	O que foi feito
Cenários	30 de clima (15 café e 15 soja) e 30 de mercado (15 café e 15 soja), controlados e reproduzíveis. Clima: normal (7), risco_unico (9), limite (9), combinado (5). Mercado: alta (6), queda (6), estavel (6), lateral_volatil (2), reversao (4), alta_com_realizacao (2), queda_com_repique (2), reversao_estavel (2).
Gabarito (clima)	Calculado pelo motor de regras real do sistema (limiares de geada, estiagem, excesso de chuva, vento e chuva na colheita). Inclui casos-limite (por exemplo 2,0 e 5,5 °C; 149 mm; 59 e 60 km/h) para testar falsos alarmes e omissões.
Gabarito (mercado)	Regra única de tendência sobre a variação líquida do período: alta se maior ou igual a +2%, queda se menor ou igual a -2%, estável entre os dois. Séries de 14 observações geradas com semente fixa; variações a pelo menos 1 ponto percentual do limiar.
Execução	Cada cenário foi enviado ao Claude duas vezes, com o mesmo prompt (clima-v1 e mercado-v2). Modelo avaliado: claude-haiku-4-5-20251001. A resposta é um JSON, validado e convertido no texto que o produtor lê.
Avaliação	Um modelo diferente e mais forte, claude-sonnet-4-6 (temperatura 0), pontuou de 1 a 5 quatro critérios, recebendo os dados enviados, o gabarito e os pontos-chave esperados. A consistência não passa pelo juiz: é calculada entre as duas execuções.
Checagens automáticas	Comparação com o gabarito (nível geral, conjunto de riscos, tendência), validade do JSON e verificação de números citados que não existem nos dados enviados.
Proveniência	Cada resposta tem requestId (req_...) e respostaId (msg_...) devolvidos pela API da Anthropic, gravados em registro-chamadas.jsonl. A avaliação não possui fallback simulado: respostas sem esses identificadores seriam excluídas e contadas.

Critérios de avaliação (escala inteira de 1 a 5)

Critério	Pergunta	5 = ... | 3 = ... | 1 = ...
Coerência	A resposta é correta e coerente com os dados e com o gabarito (níveis, tendência, riscos), sem se contradizer?	5: totalmente coerente com dados e gabarito, sem contradições | 3: pequena imprecisão ou ressalva que não muda a conclusão | 1: contradiz os dados ou o gabarito
Clareza	O texto é simples, objetivo e fácil de entender por um produtor rural?	5: direto, bem organizado, linguagem simples | 3: compreensível, mas com rodeios ou termos desnecessários | 1: confuso ou ilegível
Relevância	A resposta cobre o que importa para a decisão do produtor (pontos-chave) e evita ruído ou alarmes desnecessários?	5: cobre todos os pontos-chave e nada fora de lugar | 3: cobre parte do essencial ou traz conteúdo supérfluo | 1: omite o essencial ou foge do assunto
Ausência de informações inventadas	A resposta usa só o que está nos dados? Contexto geral só é aceitável se estiver claramente rotulado como geral.	5: nada fora dos dados fornecidos | 3: uma afirmação específica sem sustentação nos dados | 1: várias invenções (números, eventos, causas)
Consistência	As duas execuções do mesmo cenário chegam à mesma conclusão?	Calculada: nota = 1 + 4 x concordância (clima: nível geral e conjunto de riscos; mercado: mesma tendência)

4. Como a porcentagem é calculada

Indicador	Fórmula	Resultado
Índice de assertividade	média das 5 notas de cada cenário, dividida por 5 (por módulo; geral ponderado pelo número de cenários)	Clima 98,8% | Mercado 95,0% | Geral 96,9%
Acerto objetivo	respostas corretas dividido pelas respostas. Clima: nível geral e conjunto de riscos idênticos ao gabarito. Mercado: tendência igual ao gabarito	100% (120/120), IC 95%: 96,9% a 100%
Respostas satisfatórias	cenários com média das 5 notas maior ou igual a 4,0 e nenhum critério abaixo de 3	100% (60/60), IC 95%: 94,0% a 100%

Os intervalos de confiança são de Wilson (95%) e mostram a incerteza de uma amostra pequena: com 30 cenários por módulo, 100% observado é compatível com um valor verdadeiro a partir de cerca de 94%.

5. Resultados por módulo

Monitoramento climático (30 cenários, 60 respostas)

Critério	Média (1 a 5)	Desvio-padrão	% nota 4 ou mais
Coerência	5,0	0,0	100,0%
Clareza	5,0	0,1	100,0%
Relevância	4,9	0,3	100,0%
Ausência de informações inventadas	4,8	0,3	100,0%
Consistência	5,0	0,0	100,0%

Métrica objetiva (contra o motor de regras)	Valor
Respostas em JSON válido	100,0%
Nível geral correto	100,0%
Conjunto de riscos idêntico ao do motor	100,0%
Precisão dos riscos citados	100,0%
Cobertura dos riscos do motor (recall)	100,0%
Respostas com falso alarme	0,0%
Respostas citando número fora dos dados	0,0%

Categoria de cenário	Cenários	Média geral	Satisfatórios
normal	7	5,0	7 de 7
risco_unico	9	4,9	9 de 9
limite	9	4,9	9 de 9
combinado	5	5,0	5 de 5

Mercado (30 cenários, 60 respostas)

Critério	Média (1 a 5)	Desvio-padrão	% nota 4 ou mais
Coerência	4,9	0,2	100,0%
Clareza	4,7	0,5	96,7%
Relevância	4,6	0,4	100,0%
Ausência de informações inventadas	4,6	0,4	96,7%
Consistência	5,0	0,0	100,0%

Métrica objetiva (contra a regra de ±2%)	Valor
Respostas em JSON válido	100,0%
Tendência correta (alta, queda ou estável)	100,0%
Respostas citando número fora dos dados	5,0%

Gabarito \ Claude	alta	estável	queda	sem formato
alta	20	0	0	0
estável	0	20	0	0
queda	0	0	20	0

Categoria de cenário	Cenários	Média geral	Satisfatórios
alta	6	4,7	6 de 6
queda	6	4,8	6 de 6
estavel	6	4,6	6 de 6
lateral_volatil	2	4,5	2 de 2
reversao	4	4,9	4 de 4
alta_com_realizacao	2	4,9	2 de 2
queda_com_repique	2	4,9	2 de 2
reversao_estavel	2	4,8	2 de 2

6. Exemplos reais de respostas

Monitoramento climático

Maior nota - C01 (normal): Café vegetativo com clima ameno

Dados enviados ao modelo:
Talhão: Talhão C01 (café arábica, fase vegetativo)
Leitura meteorológica (fonte cenario-controlado):
- Temperatura mínima prevista nos próximos 7 dias: 14 °C
- Chuva acumulada prevista nos próximos 7 dias: 25 mm
- Dias secos consecutivos até ontem: 2
- Probabilidade máxima de chuva nos próximos 7 dias: 40%
- Vento máximo previsto: 15 km/h
- Evapotranspiração (ET0) prevista em 7 dias: 28 mm
Alertas calculados pelo motor de regras (avaliação determinística da cultura e fase):
- nenhum alerta disparado

Resposta do Claude (requestId req_011CgX6FfwV95rv4U7VgYqKS):
Nível geral: baixo
Resumo: Não há riscos relevantes identificados para o Talhão C01 nos próximos 7 dias. As condições meteorológicas previstas estão dentro dos limites seguros para a fase vegetativa do café arábica. Continue monitorando conforme o calendário regular.
Riscos: nenhum
Recomendações: nenhuma

Gabarito: Nenhum risco esperado; nível geral baixo.
Notas: coerência 5,0, clareza 5,0, relevância 5,0, ausência de invenção 5,0, consistência 5,0 (média 5,0).
Observação do avaliador: Nenhuma informação além dos dados fornecidos; sem números ou afirmações inventadas.

Menor nota - S02 (risco_unico): Estiagem crítica no enchimento de grãos (12 dias)

Dados enviados ao modelo:
Talhão: Talhão S02 (soja, fase enchimento graos)
Leitura meteorológica (fonte cenario-controlado):
- Temperatura mínima prevista nos próximos 7 dias: 14 °C
- Chuva acumulada prevista nos próximos 7 dias: 4 mm
- Dias secos consecutivos até ontem: 12
- Probabilidade máxima de chuva nos próximos 7 dias: 15%
- Vento máximo previsto: 15 km/h
- Evapotranspiração (ET0) prevista em 7 dias: 28 mm
Alertas calculados pelo motor de regras (avaliação determinística da cultura e fase):
- [alto] Risco de estiagem: 12 dias sem chuva durante enchimento_graos. Fase crítica para definição de produtividade da soja. (janela: últimos 12 dias)

Resposta do Claude (requestId req_011CgX6LF8csRbQwifuYxYUv):
Nível geral: alto
Resumo: Há risco alto de estiagem no talhão S02. A soja está em fase crítica de enchimento de grãos com 12 dias sem chuva e previsão de apenas 4 mm nos próximos 7 dias. A demanda hídrica (28 mm de evapotranspiração) está muito acima da chuva esperada.
Riscos:
- estiagem (alto): 12 dias consecutivos sem chuva durante enchimento de grãos, com previsão de apenas 4 mm de chuva e evapotranspiração de 28 mm nos próximos 7 dias.
Recomendações:
- Aumentar frequência de irrigação se disponível no talhão S02
- Monitorar diariamente o estado da cultura para sinais de seca
- Preparar sistema de irrigação pa...

Gabarito: Nível geral esperado: alto. Riscos esperados (tipo, nível): estiagem (alto).
Notas: coerência 5,0, clareza 4,5, relevância 4,0, ausência de invenção 5,0, consistência 5,0 (média 4,7).
Observação do avaliador: Todos os valores citados (12 dias, 4 mm, 28 mm) estão nos dados fornecidos. Nada inventado.

Mercado

Maior nota - MC11 (reversao): Sobe até +6% no meio e devolve tudo, fechando em -5%

Dados enviados ao modelo:
Cultura: café arábica
Unidade: saca 60kg (arábica)
Observações: 14 (de 2026-09-01 a 2026-09-14)
Preço inicial: 1680; preço final: 1596; variação: -5%
Mínimo: 1596 em 2026-09-14; máximo: 1772.28 em 2026-09-07
Série: 2026-09-01=1680; 2026-09-02=1700.46; 2026-09-03=1712.76; 2026-09-04=1730.63; 2026-09-05=1745.16; 2026-09-06=1755.35; 2026-09-07=1772.28; 2026-09-08=1764; 2026-09-09=1733.25; 2026-09-10=1704.74; 2026-09-11=1684.89; 2026-09-12=1652.51; 2026-09-13=1623.84; 2026-09-14=1596

Resposta do Claude (requestId req_011CgX6U4KidkGtBpc3jErHL):
Tendência: queda
Resumo: O preço do café arábica está em queda, recuando 5% no período de 14 dias. O preço inicial foi 1680 reais por saca, chegando a 1596 reais no final, com máxima de 1772,28 reais no dia 7 de setembro. Houve reversão clara: após sete dias de alta contínua, o mercado inverteu e caiu de forma consistente até o final do período. Recomenda-se cautela e acompanhamento próximo antes de decisões de venda, pois a queda foi acentuada e acelerada nos últimos dias.

Gabarito: Tendência esperada pela regra: queda (variação líquida de -5%; alta >= +2%, queda <= -2%, estável entre os dois). Formato da série: Sobe até +6% no meio e devolve tudo, fechando em -5%.
Notas: coerência 5,0, clareza 5,0, relevância 5,0, ausência de invenção 5,0, consistência 5,0 (média 5,0).
Observação do avaliador: Todos os dados citados constam na série fornecida; nenhuma causa ou evento externo inventado.

Menor nota - MS10 (lateral_volatil): Lateral com oscilações de ±3% e fechamento em +0,3%

Dados enviados ao modelo:
Cultura: soja
Unidade: saca 60kg
Observações: 14 (de 2026-09-01 a 2026-09-14)
Preço inicial: 128; preço final: 128.38; variação: 0.3%
Mínimo: 125.02 em 2026-09-06; máximo: 131.22 em 2026-09-09
Série: 2026-09-01=128; 2026-09-02=129.2; 2026-09-03=130.76; 2026-09-04=130.57; 2026-09-05=127.68; 2026-09-06=125.02; 2026-09-07=126.81; 2026-09-08=129.34; 2026-09-09=131.22; 2026-09-10=128.53; 2026-09-11=125.08; 2026-09-12=125.4; 2026-09-13=126.64; 2026-09-14=128.38

Resposta do Claude (requestId req_011CgX6YhwmCyrQCZw395GoQ):
Tendência: estavel
Resumo: O preço da soja manteve-se estável no período, com variação de apenas 0,3%, saindo de R$ 128,00 e fechando em R$ 128,38 a saca. A série apresentou forte volatilidade, oscilando entre R$ 125,02 (mínimo em 6 de setembro) e R$ 131,22 (máximo em 9 de setembro), evidenciando reversões significativas ao longo dos 14 dias. Após atingir o pico no meio do período, o preço recuou e se estabilizou nos últimos dias próximo ao valor inicial. Como produtor, é prudente monitorar se o preço consegue se firmar acima de R$ 128,00 ou se volta a testar os níveis mais baixos, evitando decisões precipitadas ...

Gabarito: Tendência esperada pela regra: estavel (variação líquida de 0.3%; alta >= +2%, queda <= -2%, estável entre os dois). Formato da série: Lateral com oscilações de ±3% e fechamento em +0,3%.
Notas: coerência 4,0, clareza 4,0, relevância 4,5, ausência de invenção 4,5, consistência 5,0 (média 4,4).
Observação do avaliador: Todos os dados citados estão presentes na série fornecida; nenhuma causa ou evento externo foi inventado.

7. Proveniência e consumo da API

Papel	Modelo	Chamadas ok	Falhas	Tokens de entrada	Tokens de saída
geracao	claude-haiku-4-5-20251001	120	0	68.886	24.778
juiz	claude-sonnet-4-6	120	0	145.881	22.504

Total de chamadas registradas: 241 (inclui o diagnóstico de autenticação). Execução em 29/10/2026, 16:36:36.

8. Como interpretar e limitações

- O índice de assertividade (96,9%) resume a qualidade das respostas pelos cinco critérios; o acerto objetivo (100%) mede apenas se a conclusão bate com o gabarito. São números diferentes e devem ser citados juntos.
- O resultado está próximo do teto: a medição discrimina pouco entre respostas boas. O módulo climático é uma tarefa fácil porque o modelo recebe os alertas já calculados; o resultado mede fidelidade ao motor de regras, não verdade agronômica.
- A menor média nos dois módulos foi a de 'ausência de informações inventadas' (4,8 no clima e 4,6 no mercado): detalhes sem base nos dados, como 'tutoragem', 'resistência técnica' ou 'mercado ainda busca direção'. Em seguida vêm relevância e clareza.
- O avaliador é outro modelo de linguagem e pode ter vieses. O arquivo validacao-humana.csv traz uma amostra para a equipe pontuar à mão e comparar com o juiz.
- São 30 cenários por módulo e duas execuções por cenário (amostra pequena). Os prompts foram refinados antes da medição; os números valem para as versões e o modelo indicados.
- Cenários agronomicamente ambíguos ficaram de fora para o gabarito ser inequívoco. Para um teste mais exigente: incluí-los e retirar os alertas do contexto da IA climática.